

Relatório Executivo

MLOps & Manutenção Preditiva - Indústria 4.0

Engenharia de Dados e MLOps

Dados Sintéticos: 20,000 amostras (99,5% Normal / 0,5% Falha)

Gerado em: 27/08/2026 às 11:05

Destaques

- AUC-ROC do Modelo: 0.9545
- Threshold Ótimo: 0.05 (vs. padrão 0.50)
- Economia Gerada: R\$ 402,000.00 (61.8%)
 - Recall no Threshold Ótimo: 0.8000

1. Arquitetura da Solução

1.1 Visão Geral do Pipeline

O pipeline de Machine Learning foi projetado para detectar falhas raras em equipamentos industriais a partir de dados de sensores. Os dados são gerados sinteticamente com forte desbalanceamento: 99,5% representam operação normal e apenas 0,5% representam falhas reais.

O fluxo segue as etapas: (1) Geração de dados sintéticos → (2) Divisão treino/teste estratificada → (3) Normalização com StandardScaler → (4) Treinamento do Random Forest → (5) Predição de probabilidades → (6) Avaliação de métricas → (7) Otimização financeira do threshold.

1.2 Prevenção de Data Leakage

GARANTIA CONTRA DATA LEAKAGE: A divisão entre treino (80%) e teste (20%) foi realizada ANTES de qualquer etapa de pré-processamento. O StandardScaler foi ajustado (fit) exclusivamente no conjunto de treino, e os dados de teste foram apenas transformados (transform) com os parâmetros aprendidos no treino. Isso garante que nenhuma informação estatística do conjunto de teste vazou para o processo de treinamento, mantendo a avaliação do modelo justa e confiável.

Código-chave da prevenção:

```
scaler.fit_transform(X_train) # Aprende média/desvio SÓ do treino  
scaler.transform(X_test)     # Aplica os MESMOS parâmetros no teste
```

1.3 Modelo Utilizado

Foi utilizado um Random Forest Classifier com 200 estimadores e `class_weight='balanced'`. O parâmetro `class_weight='balanced'` ajusta automaticamente os pesos das classes de forma inversamente proporcional à sua frequência, compensando o forte desbalanceamento entre operação normal (99,5%) e falha (0,5%).

2. Quadro Comparativo de Métricas

A tabela abaixo compara todas as métricas de classificação entre o threshold padrão (0.50) e o threshold ótimo encontrado pela análise financeira. Em cenários com forte desbalanceamento de classes, a Acurácia pode ser enganosa: um modelo que classifica tudo como 'Normal' atingiria ~99,5% de acurácia, porém falharia em detectar qualquer defeito real.



Métrica	Threshold 0.50	Threshold 0.05	Variação
Acurácia	0.9968	0.9750	-0.0218
Precisão	1.0000	0.1429	-0.8571
Recall	0.3500	0.8000	+0.4500
F1-Score	0.5185	0.2424	-0.2761
F2-Score	0.4023	0.4167	+0.0144
F0.5-Score	0.7292	0.1709	-0.5582
AUC-ROC	0.9545	0.9545	+0.0000
Custo Total (R\$)	R\$ 650,000	R\$ 248,000	-R\$ 402,000

2.1 Matriz de Confusão Detalhada

	TN	FP
Threshold 0.50	3980	0
Threshold 0.05	3884	96


FN	TP
13	7
4	16

2.2 Visualização das Matrizes de Confusão



3. Curva AUC-ROC


A Curva ROC (Receiver Operating Characteristic) avalia a capacidade do modelo de discriminar entre falhas e operações normais em diferentes thresholds. A área sob a curva (AUC) obtida foi de 0.9545, indicando excelente capacidade discriminativa. Um modelo aleatório teria $AUC = 0.50$.



4. Análise Financeira do Threshold

Em manutenção preditiva industrial, os custos de diferentes tipos de erro são assimétricos. Um Falso Negativo (falha não detectada) resulta em quebra de equipamento com custo estimado de R\$ 50,000. Um Falso Positivo (alarme falso) gera uma inspeção desnecessária com custo de R\$ 500.

4.1 Custo Total vs. Threshold de Decisão



4.2 Resultados da Otimização

PONTO DE MENOR CUSTO

Threshold Ótimo: 0.05

Custo Total (Ótimo): R\$ 248,000.00

Custo Total (Padrão 0.50): R\$ 650,000.00

Economia Absoluta: R\$ 402,000.00

Economia Percentual: 61.8%

Ao reduzir o threshold de decisão de 0.50 para 0.05, o modelo torna-se mais sensível a falhas, capturando mais defeitos antes que ocorram. Embora isso aumente levemente os falsos positivos (alarmes falsos), a economia total gerada pela redução drástica de falsos negativos é de R\$ 402,000.00, representando uma redução de 61.8% no custo operacional total.

5. Recomendações MLOps

Para que o modelo de manutenção preditiva opere de forma confiável em ambiente de produção industrial, é fundamental implementar um plano estruturado de monitoramento e governança.

5.1 Monitoramento de Data Drift

Implementar testes estatísticos de Kolmogorov-Smirnov (KS) em tempo real nos sensores de vibração, temperatura e pressão para identificar mudanças na distribuição dos dados que podem indicar desgaste natural do maquinário ou alterações no processo produtivo. Quando detectado drift significativo, disparar alerta para reavaliação do modelo.

5.2 Estratégia de Retreinamento

Estabelecer retreinamento automático em duas condições:

- Periódico: mensal, com dados acumulados dos últimos 90 dias.
- Por gatilho: quando a métrica F2-Score cair abaixo de 0.80, indicando degradação na capacidade de detecção de falhas.

O retreinamento deve incluir validação temporal (time-series split) para garantir que o modelo generaliza para dados futuros.

5.3 Feature Store e Governança

Centralizar o pipeline de transformação (Scalers, Encoders) em uma Feature Store para garantir simetria entre o ambiente de treinamento e a inferência na borda (Edge Computing). Todas as transformações devem ser versionadas e auditáveis.

5.4 Protocolo de Fallback de Segurança

Em caso de indisponibilidade do modelo (timeout, erro de infraestrutura) ou dados corrompidos nos sensores, a linha de montagem deve assumir um estado preventivo reduzido com alerta automático à equipe de manutenção. Isso garante que falhas de ML não comprometam a segurança operacional.

5.5 Registro e Versionamento de Modelos

Utilizar ferramentas como MLflow ou similares para registrar:

- Versão do modelo e hiperparâmetros utilizados.
- Métricas de avaliação em cada retreinamento.
- Threshold de decisão ativo em produção.
- Dataset e features utilizados para treinamento.

Isso permite rastreabilidade completa e rollback rápido caso um novo modelo apresente performance inferior.